PROPOSAL PENELITIAN

Analisis Pengaruh Interval Agregasi Data terhadap Akurasi Prediksi Volume Trafik Jaringan pada Horizon Prediksi yang Sama

JUDUL PENELITIAN	Analisis Pengaruh Interval Agregasi Data terhadap Akurasi Prediksi Volume Trafik Jaringan pada Horizon Prediksi yang Sama
Nama	[Isi nama peneliti]
NPM / NIM	[Isi NPM / NIM]
Program Studi	[Isi program studi]
Mata Kuliah	[Isi nama mata kuliah jika diperlukan]

BAB I: PENDAHULUAN

1.1 Latar Belakang

Prediksi volume trafik jaringan dapat mendukung pemantauan, perencanaan kapasitas, dan pengelolaan sumber daya. Data historis jumlah byte atau paket digunakan untuk memperkirakan beban trafik periode berikutnya. Kualitas prediksi tidak hanya dipengaruhi algoritma, tetapi juga cara data diringkas dan interval waktu yang membentuk setiap titik deret waktu.

Interval agregasi yang rapat mempertahankan perubahan jangka pendek, tetapi menghasilkan lebih banyak titik dan dapat menangkap fluktuasi cepat. Interval lebih panjang lebih ringkas, namun berpotensi menghilangkan perubahan trafik yang singkat. Studi trafik jalan menunjukkan resolusi temporal dapat berkaitan dengan akurasi prediksi, tetapi hasilnya tidak otomatis berlaku pada jaringan komputer [2, 3].

Penelitian ini menggunakan dataset publik CESNET-TimeSeries24 dari pemantauan jaringan CESNET3. Dataset menyediakan deret waktu pada interval 10 menit dan 1 jam, pada tingkat institusi, subnet institusi, dan alamat IP; metrik volumenya mencakup jumlah byte (`n_bytes`) per interval [1]. Dengan sumber data yang sama, kedua interval dapat dibandingkan tanpa menggabungkan pengukuran dari sistem berbeda.

Penelitian membandingkan interval 10 menit dan 1 jam dengan horizon yang sama, yakni volume trafik satu jam berikutnya. Penyamaan horizon mencegah efek interval masukan tercampur dengan durasi target. Hasilnya akan menunjukkan apakah resolusi lebih rapat memberi keuntungan akurasi yang konsisten atau interval satu jam menghasilkan kinerja sebanding dengan data yang lebih ringkas.

1.2 Rumusan Masalah

1. Bagaimana perbedaan akurasi prediksi volume trafik jaringan antara interval agregasi 10 menit dan 1 jam ketika horizon prediksi keduanya sama-sama satu jam ke depan?

2. Interval agregasi mana yang menghasilkan kesalahan prediksi lebih rendah berdasarkan MAE, RMSE, dan WAPE pada seri trafik institusi yang diuji?

3. Apakah perbedaan kinerja antara kedua interval konsisten pada beberapa seri trafik institusi, atau hanya terlihat pada seri tertentu?

BAB I: PENDAHULUAN (LANJUTAN)

1.3 Batasan Masalah

1. Penelitian menggunakan dataset publik CESNET-TimeSeries24; nama dataset dicantumkan pada metodologi dan tidak menjadi bagian dari judul penelitian.

2. Analisis difokuskan pada seri tingkat institusi yang tersedia pada interval 10 menit dan 1 jam. Pemilihan seri akhir dilakukan setelah pemeriksaan kelengkapan dan keselarasan waktu, dengan kriteria yang dicatat dalam laporan eksperimen.

3. Variabel target adalah volume trafik yang direpresentasikan oleh jumlah byte (`n_bytes`) dalam suatu interval. Penelitian tidak mengukur latensi, jitter, packet loss, kapasitas link, atau utilisasi link secara langsung.

4. Horizon prediksi disamakan menjadi volume untuk satu jam berikutnya. Untuk data 10 menit, target dibentuk dengan menjumlahkan enam interval 10 menit berikutnya; pada data 1 jam, target adalah jumlah byte pada interval satu jam berikutnya. Titik waktu prediksi harus disejajarkan.

5. Model utama adalah Random Forest Regression dengan baseline sederhana berbasis volume satu jam terakhir. Penelitian tidak mencakup implementasi kontrol jaringan langsung atau pengubahan rute.

6. Data dibagi berdasarkan urutan waktu, bukan diacak, sehingga periode pengujian berada setelah periode pelatihan dan validasi.

1.4 Tujuan Penelitian

1. Membandingkan akurasi prediksi volume trafik jaringan menggunakan interval agregasi 10 menit dan 1 jam dengan horizon prediksi yang sama.

2. Mengukur dan melaporkan perbedaan kesalahan prediksi menggunakan MAE, RMSE, dan WAPE pada periode pengujian yang sebanding.

3. Mengevaluasi variasi hasil antarseri trafik institusi untuk menilai konsistensi hasil perbandingan.

4. Menyusun rekomendasi awal mengenai pemilihan interval agregasi untuk eksperimen prediksi volume trafik, berdasarkan hasil empiris dan keterbatasan dataset.

1.5 Manfaat Penelitian

Manfaat akademis. Menambah bukti empiris mengenai pengaruh resolusi temporal terhadap prediksi volume trafik jaringan komputer, dengan prosedur yang membandingkan horizon dan titik pengujian secara selaras.

Manfaat praktis. Memberikan pertimbangan awal bagi analis atau administrator jaringan dalam memilih interval agregasi data untuk pemantauan historis dan peramalan volume trafik. Temuan tidak langsung dianggap berlaku untuk seluruh jaringan karena dataset berasal dari satu lingkungan pemantauan.

Catatan ruang lingkup: Proposal ini merupakan rencana penelitian. Angka hasil eksperimen, interval yang terbaik, dan signifikansi statistik belum ditentukan serta tidak diasumsikan sebelum eksperimen dijalankan.

BAB II: TINJAUAN PUSTAKA DAN KERANGKA PEMIKIRAN

2.1 Landasan Teori

Volume trafik jaringan. Volume trafik direpresentasikan oleh jumlah byte atau paket dalam suatu interval. Pada dataset yang digunakan, `n_bytes` menyatakan jumlah byte per interval [1]. Target dinyatakan sebagai byte per jam, bukan bit per detik atau utilisasi kapasitas link.

Deret waktu dan prediksi. Deret waktu adalah observasi berurutan menurut waktu. Model menggunakan riwayat untuk memperkirakan nilai berikutnya. Pembagian data secara temporal lebih sesuai daripada pengacakan karena penelitian memprediksi periode setelah data historis.

Interval agregasi. Interval agregasi menetapkan durasi yang diwakili setiap titik. Pada CESNET-TimeSeries24, metrik jumlah byte dijumlahkan saat membentuk interval lebih besar [1]. Penelitian menggunakan interval 10 menit dan 1 jam untuk memprediksi volume satu jam mendatang.

Random Forest Regression. Random Forest adalah metode ensemble yang menggabungkan prediksi sejumlah pohon keputusan. Metode ini digunakan sebagai model utama; baseline volume satu jam terakhir menjadi pembanding sederhana.

Metrik evaluasi. MAE mengukur rata-rata kesalahan absolut; RMSE lebih sensitif terhadap kesalahan besar; WAPE membandingkan total kesalahan absolut dengan total aktual. Semua metrik dihitung untuk volume satu jam mendatang; WAPE membantu membandingkan seri dengan skala trafik berbeda.

2.2 Penelitian Terkait

Rujukan	Fokus dan temuan yang relevan	Kaitan dengan penelitian ini
[1] Koumar dkk. (2025)	Memperkenalkan CESNET-TimeSeries24 untuk analisis anomali dan forecasting; menyediakan interval 10 menit, 1 jam, dan 1 hari.	Menjadi sumber dataset; mendukung pelaporan interval agregasi dan pra-pemrosesan secara jelas.
[2] Weerasekera dkk. (2020)	Menguji resolusi data untuk prediksi trafik jalan dengan ANN, Random Forest, dan SVR; data resolusi tinggi memberi hasil lebih baik pada konteks yang dikaji.	Relevan dengan pertanyaan resolusi, tetapi domainnya trafik jalan dan tidak langsung mewakili jaringan komputer.
[3] Pavlyuk (2020)	Menganalisis efek agregasi temporal terhadap peramalan trafik perkotaan dengan beberapa model deret waktu.	Menunjukkan pentingnya pilihan agregasi, tetapi konteks datanya berbeda dari trafik jaringan.
[4] Rusek & Drton (2023)	Mengkaji prediksi trafik jaringan dengan menghubungkan deret waktu agregat dan prediksi lebih rinci.	Dekat dengan domain penelitian dan mendukung kajian antarlevel agregasi.

BAB II: TINJAUAN PUSTAKA DAN KERANGKA PEMIKIRAN (LANJUTAN)

2.3 Kesenjangan Penelitian (Research Gap) dan Kebaruan yang Diusulkan

Studi sebelumnya mengkaji efek agregasi pada trafik transportasi, sementara Rusek dan Drton membahas prediksi trafik jaringan dari data bergranularitas kasar [2-4]. CESNET-TimeSeries24 menyediakan beberapa interval untuk trafik jaringan komputer [1]. Kontribusi yang diuji bukan klaim bahwa efek agregasi belum pernah dipelajari, melainkan perbandingan terkontrol volume byte dengan horizon satu jam yang disamakan.

Kontribusi yang direncanakan: (1) membentuk target satu jam yang sebanding; (2) menyelaraskan timestamp dan periode uji; (3) mengevaluasi beberapa seri institusi; dan (4) membandingkan model dengan baseline. Gap ini masih awal dan perlu diperkuat melalui penelusuran literatur sistematis.

2.4 Kerangka Pemikiran Penelitian

Tahap	Komponen dan alur logika
1. Data	Mengambil deret volume byte tingkat institusi pada interval 10 menit dan 1 jam dari satu sumber dataset.
2. Pra-pemrosesan	Memeriksa kelengkapan, waktu, nilai hilang, duplikasi, dan kriteria seri.
3. Pembentukan target	Menjumlahkan enam titik 10 menit berikutnya; membandingkan dengan satu titik jam berikutnya.
4. Pemodelan	Menguji Random Forest Regression dan baseline volume satu jam terakhir dengan pembagian data kronologis.
5. Evaluasi	Menghitung MAE, RMSE, WAPE dan membandingkan waktu target yang sama.
6. Luaran	Kesimpulan tentang pengaruh interval agregasi pada eksperimen ini serta rekomendasi dan batasan penerapannya.

2.5 Hipotesis Penelitian

H0: Tidak terdapat perbedaan pada kesalahan WAPE berpasangan antara prediksi berbasis interval 10 menit dan interval 1 jam ketika keduanya memprediksi volume satu jam pada waktu target yang sama.

H1: Terdapat perbedaan pada kesalahan WAPE berpasangan antara kedua interval agregasi pada kondisi pengujian tersebut. Pengujian direncanakan menggunakan Wilcoxon signed-rank pada tingkat signifikansi 0,05 jika jumlah seri valid memadai. MAE dan RMSE menjadi metrik sekunder untuk melengkapi interpretasi.

BAB III: METODOLOGI PENELITIAN

3.1 Desain Penelitian

Penelitian dirancang sebagai eksperimen kuantitatif komparatif berbasis data sekunder. Faktor yang dibandingkan adalah interval agregasi masukan (10 menit dan 1 jam), sedangkan target prediksi, horizon, periode pengujian, dan jenis model dijaga sebanding. Variabel hasil adalah kesalahan prediksi volume trafik untuk satu jam berikutnya.

3.2 Sumber Data dan Variabel Penelitian

Dataset CESNET-TimeSeries24 tersedia di Zenodo dan diperkenalkan dalam artikel Scientific Data tahun 2025 [1, 5]. Dataset memuat sekitar 40 minggu pemantauan CESNET3 dan seri pada tingkat institusi, subnet, serta alamat IP. Unit analisis adalah seri institusi yang tersedia pada kedua interval. Jumlah akhir dilaporkan setelah pemeriksaan file dan kelengkapan data.

Jenis	Variabel / definisi	Penggunaan
Variabel target	`n_bytes`: jumlah byte pada interval agregasi.	Volume aktual satu jam mendatang yang akan diprediksi.
Variabel masukan	Riwayat nilai `n_bytes` selama enam jam sebelum waktu prediksi.	36 nilai lag untuk interval 10 menit; 6 nilai lag untuk interval 1 jam.
Faktor pembanding	Interval agregasi 10 menit vs. 1 jam.	Kondisi eksperimen utama.
Metrik evaluasi	MAE, RMSE, dan WAPE.	Mengukur kesalahan pada target satu jam yang sama.

3.3 Pra-pemrosesan dan Pembentukan Data

1. Memuat seri institusi pada interval 10 menit dan 1 jam serta memetakan `id_time` ke waktu kalender berdasarkan berkas waktu yang disediakan dataset.

2. Memastikan dua interval berasal dari institusi yang sama; memeriksa duplikasi timestamp, titik hilang, nilai tidak valid, dan kesinambungan waktu. Nilai nol tidak otomatis dianggap hilang karena dapat menunjukkan tidak ada byte tercatat.

3. Menetapkan kriteria kelengkapan sebelum pengujian. Ambang awal yang diusulkan adalah minimal 95% titik tersedia; setiap perubahan kriteria dicatat dan dijustifikasi.

4. Menentukan waktu prediksi pada batas jam yang sama. Kondisi 10 menit memakai 36 nilai sebelumnya dan jumlah enam nilai berikutnya sebagai target; kondisi 1 jam memakai enam nilai sebelumnya dan nilai jam berikutnya.

5. Memeriksa kesepadanan jumlah enam nilai `n_bytes` berinterval 10 menit dengan volume interval 1 jam. Perbedaan skema atau batas interval harus diselesaikan sebelum pemodelan.

3.4 Pembagian Data dan Pemodelan

Data dibagi kronologis: rancangan awal 70% periode awal untuk pelatihan, 15% berikutnya untuk validasi, dan 15% terakhir untuk pengujian. Rentang tanggal sama diterapkan pada kedua interval. Data uji hanya digunakan untuk evaluasi final.

Model utama adalah Random Forest Regression. Parameter ditetapkan sebelum evaluasi akhir atau dipilih hanya dengan data validasi; prosedurnya dibuat sebanding untuk dua kondisi. Baseline memprediksi volume berikutnya dari volume satu jam terakhir: jumlah enam interval sebelumnya pada kondisi 10 menit atau satu titik sebelumnya pada kondisi 1 jam.

BAB III: METODOLOGI PENELITIAN (LANJUTAN)

3.5 Metrik Evaluasi

Seluruh metrik dihitung pada target volume satu jam yang sama. Untuk setiap seri institusi, MAE dan RMSE dihitung pada periode uji. WAPE dihitung sebagai total kesalahan absolut dibagi total nilai aktual pada periode uji, dikalikan 100%. Hasil dilaporkan per seri dan diringkas lintas seri agar institusi dengan volume terbesar tidak menjadi satu-satunya penentu kesimpulan.

Mean Absolute Error (MAE)

$$MAE = (1/N) \times \Sigma |y_i - \hat{y}_i|$$

Root Mean Squared Error (RMSE)

$$RMSE = \sqrt{[(1/N) \times \Sigma (y_i - \hat{y}_i)^2]}$$

Weighted Absolute Percentage Error (WAPE)

$$WAPE = [\Sigma |y_i - \hat{y}_i| / \Sigma |y_i|] \times 100\%$$

dengan y_i sebagai volume aktual, $\hat{y}_i$ sebagai prediksi, dan N sebagai jumlah waktu target pengujian. Nilai MAE dan RMSE yang lebih rendah menandakan kesalahan lebih kecil. WAPE juga lebih rendah jika total kesalahan relatif terhadap volume aktual lebih kecil. Jika total volume aktual suatu seri bernilai nol, WAPE untuk seri itu tidak terdefinisi dan harus ditandai, bukan dipaksakan menjadi angka.

3.6 Analisis Perbandingan dan Uji Statistik

1. Membandingkan metrik pada target waktu yang sama dan distribusi kesalahan per institusi.

2. Melaporkan mean, median selisih, variasi antarseri, serta proporsi seri yang lebih baik pada tiap interval.

3. Jika jumlah seri memadai, gunakan uji Wilcoxon signed-rank pada kesalahan berpasangan per institusi. Taraf signifikansi awal $\alpha = 0{,}05$; hasil ditafsirkan bersama ukuran efek dan ketidakpastian.

4. Periksa apakah kesimpulan didominasi seri bervolume ekstrem. Sajikan ringkasan lintas institusi dan kurva aktual-prediksi.

3.7 Perangkat dan Tahapan Pelaksanaan

Tahap	Aktivitas	Luaran
1. Studi literatur	Menelaah agregasi temporal, forecasting jaringan, dan panduan dataset.	Landasan teori dan gap yang diperbarui.
2. Akuisisi data	Mengunduh arsip institusi dan indeks waktu.	Data mentah terarsip dan catatan sumber.
3. Persiapan data	Menyiapkan dua interval dan memeriksa kelengkapan serta kesepadanan target.	Dataset eksperimen siap pakai.
4. Eksperimen	Melatih baseline dan Random Forest dengan horizon satu jam.	Prediksi, metrik, dan log eksperimen.
5. Analisis	Membandingkan metrik, konsistensi antarseri, dan keterbatasan.	Tabel, grafik, dan kesimpulan.

Perangkat yang direncanakan adalah Python, pandas, scikit-learn, dan matplotlib untuk pengolahan, pemodelan, evaluasi, serta visualisasi. Seri tingkat institusi dipilih agar beban pemrosesan lebih terkendali daripada seluruh seri IP.

3.8 Batasan Interpretasi

Penelitian memprediksi volume byte, bukan pengendalian jaringan langsung. Hasil tidak membuktikan peningkatan utilisasi link, penurunan kemacetan, atau peningkatan QoS. Generalisasi juga terbatas karena data berasal dari satu jaringan penelitian dan pendidikan di Republik Ceko.

DAFTAR PUSTAKA

[1] J. Koumar, K. Hynek, T. Čejka, and P. Šiška, “CESNET-TimeSeries24: Time Series Dataset for Network Traffic Anomaly Detection and Forecasting,” *Scientific Data*, vol. 12, article 338, 2025. doi: 10.1038/s41597-025-04603-x. Tersedia: https://doi.org/10.1038/s41597-025-04603-x

[2] R. Weerasekera, M. Sridharan, and P. Ranjitkar, “Implications of Spatiotemporal Data Aggregation on Short-Term Traffic Prediction Using Machine Learning Algorithms,” *Journal of Advanced Transportation*, vol. 2020, article 7057519, 2020. doi: 10.1155/2020/7057519. Tersedia: https://doi.org/10.1155/2020/7057519

[3] D. Pavlyuk, “Temporal Aggregation Effects in Spatiotemporal Traffic Modelling,” *Sensors*, vol. 20, no. 23, article 6931, 2020. doi: 10.3390/s20236931. Tersedia: https://doi.org/10.3390/s20236931

[4] K. Rusek and M. Drton, “Fine-grained Network Traffic Prediction from Coarse Data,” *Austrian Journal of Statistics*, vol. 52, no. 3, pp. 114-123, 2023. doi: 10.17713/ajs.v52i3.1471. Tersedia: https://doi.org/10.17713/ajs.v52i3.1471

[5] CESNET, “CESNET-TimeSeries24: Time Series Dataset for Network Traffic Anomaly Detection and Forecasting,” dataset, Zenodo, 2024. doi: 10.5281/zenodo.13382427. Tersedia: https://zenodo.org/records/13382427

Catatan penyusunan

Proposal ini merupakan draf awal untuk dikembangkan. Sebelum diserahkan, isi identitas peneliti, cocokkan format sitasi dengan pedoman kampus, dan lakukan penelusuran literatur yang lebih luas untuk memperkuat research gap. Seluruh klaim mengenai kinerja model, hasil statistik, serta interval terbaik baru boleh dituliskan setelah eksperimen selesai.